

徐彬琰

binyxu@ie.cuhk.edu.hk • +86 159-5123-4880 • 个人主页 • Semantic Scholar • GitHub • LinkedIn

教育背景

香港中文大学	2023.9 – 2027.10 (预计)
信息工程博士研究生; 导师: 张克环教授	GPA: 3.914
加州大学伯克利分校	2021.8 – 2021.12
电子工程与计算机科学交换项目	GPA: 4.0
西安交通大学	2019.9 – 2023.7
自动化工学学士, 钱学森学院, 钱学森班	GPA: 3.92; 排名: 前 5%
• 通过少年班从初中阶段进入西安交通大学; 该选拔项目从 4,000+ 名申请者中录取约 100 人。	

研究主线与定位

🔗 长程自主智能: 状态管理、经验学习与技能演进

- 研究 LLM agent 如何感知并管理运行状态, 将不断增长的上下文与交互轨迹沉淀为可复用经验和技能, 提升开放环境中的长程推理、工具使用与自主学习能力。
- 形成“运行状态感知—上下文管理—经验巩固—技能内化”主线: 提出训练无关的 VISTA 状态接口, 研究检索式记忆的泛化边界, 并以技能蒸馏与 GRPO 探索经验内化。
- 主导 4 篇 CCF-A 已录用、4 篇在投的第一作者工作; 当前聚焦 long-horizon agents、self-managed context、agentic memory、trajectory/skill learning 与 agent post-training。

代表论文与投稿

4 篇 CCF-A 类会议已录用、4 篇在投, 均为第一作者工作。

一、长程自主智能: 状态管理、经验学习与技能演进

[1] **LLM Agents Are Latent Context Managers: Eliciting Self-Management via Proprioception**  在投
Binyan Xu, Haitao Li, Kehuan Zhang.

Agentic RL: 显式暴露运行状态, 构建 context-tool 动作空间并以 GRPO 学习自适应策略。

[2] **From Multi-Agent to Single-Agent: When Is Skill Distillation Beneficial?**  在投
Binyan Xu, Dong Fang, Haitao Li, Kehuan Zhang.

轨迹与技能学习: 判断何时可将多智能体协作及评测闭环内化为低成本单智能体能力。

[3] **Contextual Agentic Memory is a Memo, Not True Memory**  在投
Binyan Xu*, Xilin Dai*, Kehuan Zhang. *Equal contribution.

经验巩固: 区分临时上下文检索与可泛化经验, 重新定义 agent memory。

二、基础模型作为外部验证器: 行为验证与模型引导

[4] **From Internal Diagnosis to External Auditing: A VLM-Driven Paradigm for Online Defense**  ICML 2026
Binyan Xu, Xilin Dai, Fan Yang, Di Tang, Kehuan Zhang. Poster

模型验证: 以通用 VLM 作为模型无关的在线 verifier, 避免依赖目标模型内部诊断。

[5] **CLIP-Guided Backdoor Defense through Entropy-Based Poisoned Dataset Separation**  ACM MM
Binyan Xu, Fan Yang, Xilin Dai, Di Tang, Kehuan Zhang.  Oral Presentation

模型引导: 利用 CLIP 开放语义信号进行训练数据选择与教师指导。

三、开放模型行为与自主执行: 能力迁移、风险边界与现实影响

[6] **One Surrogate to Fool Them All: Universal and Transferable Adversarial Attacks with CLIP**  CCS 2025
Binyan Xu, Xilin Dai, Di Tang, Kehuan Zhang.  Oral Presentation

语义迁移: 研究公开 CLIP 表征如何跨模型、跨任务迁移至真实黑盒 AI 服务。

[7] **Breaking Stealth-Potency Trade-off in Clean-Image Backdoors with Trigger Optimization**  AAAI 2026
Binyan Xu, Xilin Dai, Fan Yang, Di Tang, Kehuan Zhang.  Oral Presentation

行为边界: 以生成式建模揭示少量训练数据如何诱导隐蔽且可迁移的模型行为。

[8] **When Agent Automation Becomes Profitable: Quantify and Insure Autonomous AI Risk**  在投
Binyan Xu, Xilin Dai, Fan Yang, Kehuan Zhang.

自主执行: 将工具轨迹映射为任务损失与控制信号, 刻画 Agent 自动化的部署边界。

项目经历

长程 LLM Agent：状态管理、经验学习与技能演进2026.1 – 2026.7

腾讯 IEG，光子工作室群，X-Data Research Team；青云计划实习全职研究实习生

- 主导 *LLM Agents Are Latent Context Managers* [1]，提出智能体缺失对自身上下文状态的 *proprioception*，设计 VISTA self-managed context 层，将工作记忆表示为 typed/addressable blocks，并暴露 token usage、recency 与 budget 等状态。
- 在 LOCA-Bench 75 个长程工具任务上将 Gemini-3-Flash 成功率从 22.7% 提升至 50.7%，优于 ReAct、SLIM、Active Context Compression 与 Claude Code。
- 构建 context-tool 动作空间及 GRPO 后训练/评测闭环：显式状态接口在 BC+ 同分布/GAIA→BC+ 跨分布达 31.3%/21.3%，超过对应基线 27.3%/17.3%，验证状态表示与 post-training 互补。
- 主导技能蒸馏研究 [2]，提出 *Metric Freedom* 判断何时可将多智能体协作/评测结构内化为单 agent 技能；在 4 项任务、11 个数据集上以 1.4-15× 更低成本达到或超过原系统。
- 共同主导 agentic memory 研究 [3]，指出当前“记忆”模块多为上下文扩展而非真正记忆系统；构建评测、消融、统计分析与可复现 artifact，支撑智能体从临时上下文走向可复用经验。

多模态可控生成：美学平面设计自动化2022.7 – 2023.6

微软亚洲研究院，Data, Knowledge and Intelligence；明日之星实习项目全职研究实习生

- 共同开发 AI 辅助美学设计系统，结合版式规划、视觉语言理解与扩散式风格/装饰生成，面向真实设计中的可控内容生成。
- 实现可控生成模块，在提升视觉质量的同时降低版式、元素关系与设计约束违背，为后续研究可控生成、约束满足与人机反馈闭环提供应用侧经验。
- 获得微软亚洲研究院 Stars of Tomorrow Internship Program 的 *Award of Excellence*。

基础模型行为：外部验证、语义迁移与风险边界2023.9 – 2026.1

香港中文大学应用安全研究实验室博士阶段研究

- 研究通用基础模型的开放语义能力如何迁移并指导下游系统，覆盖 VLM 在线验证、CLIP 引导的数据选择、跨模型语义迁移与生成式行为优化 [4-8]。
- 提出以 VLM 作为外部 verifier 的数据无关在线验证方法 [4]，将目标模型行为与独立语义判断解耦，适用于内部状态不可访问或不完全可信的部署场景。
- 设计通用语义触发器优化方法 [7]，验证表征可跨真实 AI 服务（谷歌搜图、百度搜图、淘宝识图）和多模态模型（GPT-4、Claude Sonnet 等）迁移。
- 构建 CLIP 引导的数据筛分、模型指导与跨模型迁移流程 [5,6]；产出 ICML、AAAI、CCS 与 ACM MM 等 CCF-A 论文，积累 foundation-model evaluation 与 model-agnostic verification 经验。

开源与影响力

- 在 github.com/binyxu 开源第一作者工作代码，覆盖 long-horizon agent 评测、VISTA self-managed context、agentic memory、技能蒸馏、VLM 外部审计、后门攻防与对抗迁移。
- Agent-memory 工作发布后引发较广泛讨论，包括 DAIR.AI 在 X 上转发（26K+ 浏览、700+ 点赞/收藏）、Facebook AI 社区、YouTube 解读、小红书转载与新智元报道。

荣誉与技能

- 学术服务: ICML、ICLR、ACM MM、AAAI 正式审稿人；AAAI、ACM CCS、ACM MM 口头报告，ICML poster 展示；Lead TA 指导 40+ 名本科毕业设计学生。
- 荣誉: 美国大学生数学建模竞赛 Finalist（Top 2%）；入选西安交通大学少年班（4,000+ 名申请者中前 2.5%）；钱学森班荣誉毕业生/优秀毕业生；伯克利交换项目一等资助；微软亚洲研究院 Stars of Tomorrow Award of Excellence。
- 研究方向: long-horizon LLM agents、self-managed context、agentic memory、trajectory/skill learning、agent post-training/GRPO、inference-time scaling。
- 编程与工具: Python（主力）；PyTorch、Hugging Face、vLLM、FSDP、veRL；GRPO 后训练、agent harness、多轮环境交互、tool-use evaluation 与多卡实验。
- 语言: 中文（母语），英语（流利；TOEFL 104）。