

徐彬琰

binyxu@ie.cuhk.edu.hk • +86 159-5123-4880 • 个人主页 • Semantic Scholar • GitHub • LinkedIn

教育背景

香港中文大学

2023.9 – 2027.8 (预计)

信息工程博士研究生；导师：张克环教授

GPA: 3.86

加州大学伯克利分校

2021.8 – 2021.12

电子工程与计算机科学交换项目

GPA: 4.0

- 主要课程：Introduction to Embedded Systems (A; Sanjit Seshia), Optimization Models in Engineering (A+; L. El Ghaoui), Dynamic Systems and Feedback (A+; Kameshwar Poolla)。

西安交通大学

2019.9 – 2023.7

自动化工学学士，钱学森学院，钱学森班

GPA: 3.92; 排名: 前 5%

- 通过少年班从初中阶段进入西安交通大学；该选拔项目从 4,000+ 名申请者中录取约 100 人。

代表论文与投稿

9 项工作均为 CCF-A 类会议录用或在审，其中 7 项为第一/共同第一作者工作。

[1] **Binyan Xu***, Xilin Dai*, Kehuan Zhang. Contextual Agentic Memory is a Memo, Not True Memory. Under review at *NeurIPS 2026*. *Equal contribution.

[2] **Binyan Xu**, Dong Fang, Haitao Li, Kehuan Zhang. From Multi-Agent to Single-Agent: When Is Skill Distillation Beneficial? Under review at *NeurIPS 2026*.

[3] **Binyan Xu**, Xilin Dai, Fan Yang, Kehuan Zhang. Reviewer Scores Are Not Comparable Across Research Areas in ML Peer Review. Under review at *NeurIPS 2026*.

[4] **Binyan Xu**, Xilin Dai, Fan Yang, Di Tang, Kehuan Zhang. From Internal Diagnosis to External Auditing: A VLM-Driven Paradigm for Data-Free Online Backdoor Defense. In *Proceedings of the 43rd International Conference on Machine Learning (ICML)*, PMLR 306, Seoul, South Korea, 2026. **Poster**.

[5] **Binyan Xu**, Xilin Dai, Fan Yang, Di Tang, Kehuan Zhang. Breaking the Stealth-Potency Trade-off in Clean-Image Backdoors with Generative Trigger Optimization. In *AAAI Conference on Artificial Intelligence (AAAI)*, 2026. **Oral Presentation**.

[6] **Binyan Xu**, Xilin Dai, Di Tang, Kehuan Zhang. One Surrogate to Fool Them All: Universal, Transferable, and Targeted Adversarial Attacks with CLIP. In *ACM Conference on Computer and Communications Security (CCS)*, 2025. **Oral Presentation**.

[7] **Binyan Xu**, Fan Yang, Xilin Dai, Di Tang, Kehuan Zhang. CLIP-Guided Backdoor Defense through Entropy-Based Poisoned Dataset Separation. In *ACM International Conference on Multimedia (ACM MM)*, 2025. **Oral Presentation**.

[8] Fan Yang, **Binyan Xu**, Di Tang, Kehuan Zhang. Beyond Nodes vs. Edges: A Multi-View Fusion Framework for Provenance-Based Intrusion Detection. In *IEEE Symposium on Security and Privacy (S&P)*, 2026.

[9] Fan Yang, **Binyan Xu**, Di Tang, Kehuan Zhang. Trapping Attacker in Dilemma: Examining Internal Correlations and External Influences of Trigger for Defending GNN Backdoors. Under review at *NeurIPS 2026*.

科研经历

智能体系统：记忆、技能蒸馏与评测

2026.1 – 2026.5

腾讯 IEG, 光子工作室群, X-Data Research Team; 青云计划实习

全职研究实习生

- 主导 NeurIPS 投稿，研究何时可将多智能体系统蒸馏为单智能体技能，并提出 *Metric Freedom* 预测技能收益。
- 开发自适应技能蒸馏流程，在 4 项任务、11 个数据集上以 1.4–15× 更低成本达到或超过原系统。
- 共同主导智能体上下文记忆研究，指出当前“记忆”模块多为上下文扩展而非真正记忆系统，并开源代码与分析流程。
- 构建智能体评测、消融、统计分析、提示优化与可复现 artifact 发布流程。

AI 辅助美学平面设计生成

2022.7 – 2023.6

微软亚洲研究院, Data, Knowledge and Intelligence; 明日之星实习项目

全职研究实习生

- 开发 AI 辅助美学设计系统，结合自回归视觉语言布局生成与扩散式风格/装饰生成。
- 实现可控生成模块，提高视觉质量并降低专业平面设计流程中的约束违背。
- 获得微软亚洲研究院 Stars of Tomorrow Internship Program 的 *Award of Excellence*。

基础模型辅助的神经网络攻防研究

2023.9 – 2026.1

香港中文大学应用安全研究实验室

博士阶段研究

- 主导多项多模态基础模型安全研究，覆盖 VLM 外部审计、多模态大模型引导毒化数据分离、CLIP 迁移攻击与生成式 clean-image 后门。
- 提出以 VLM 作为外部审计者的数据无关在线后门防御方法，将防御从模型内部诊断转向外部语义审计。
- 设计通用触发器优化方法，在多个真实 AI 服务（例如谷歌搜图，百度搜图，淘宝识图）和多模态模型（GPT-4, Claude Sonnet 等）上保持高成功率。
- 构建 CLIP 引导的通用定向攻击和毒化数据集分离流程；产出 ICML、AAAI、CCS、ACM MM 四篇 CCF-A 第一作者论文。

机器学习会议同行评审公平性与测量设计

2025.12 – 2026.3

香港中文大学应用安全研究实验室

博士阶段研究

- 审计 ICLR 2021–2026 共 50,289 篇论文、219 个主题，发现同等 reviewer score 下不同主题论文录取概率最高可相差 8×。
- 使用回归、似然比检验、置换检验、主题建模、阈值估计与稳健性检验排除替代解释，并发布交互式分析网站。
- 主张将 topic-stratified, score-conditional acceptance rate 作为机器学习会议评审公平性指标。

开源与社区影响

- 在 github.com/binyxu 开源第一作者工作代码，覆盖智能体评测、技能蒸馏、后门攻防、对抗迁移与同行评审分析。
- 发布智能体记忆评测、自适应技能蒸馏、VLM 外部审计、生成式触发器优化、CLIP 迁移与 ICLR 主题分析的可复现实现。
- Agent-memory 工作发布后引发较广泛讨论，包括 DAIR.AI 在 X 上转发（26K+ 浏览、700+ 点赞/收藏）、Facebook AI 社区、YouTube 解读、小红书转载与新智元报道。
- 同行评审公平性分析被 PaperWeekly 报道并在小红书讨论，相关内容累计获得 40K+ 浏览、1,200+ 转发与 900+ 点赞。

教学与学术服务

Lead Teaching Assistant, IERG 4998/4999 Final Year Project I/II

2023 – 2026

香港中文大学

- 累计指导 40+ 名本科毕业设计学生，负责 proposal、技术方向、报告、展示反馈与评分，并协调反馈标准。
- 指导学生进行研究问题定义、实验设计、技术写作与展示表达。

学术服务与会议报告

- 正式审稿人: ICML (6 篇), ICLR (2 篇), ACM MM (2 篇), AAAI (1 篇)。
- 会议报告: AAAI、ACM CCS、ACM MM 口头报告; ICML poster 展示。

获奖与荣誉

- 美国大学生数学建模竞赛 Finalist, COMAP, 2021 (Top 2%)。
- 伯克利交换项目一等资助, 2021 (Top 5%; 约 RMB 10 万)。
- 西安交通大学钱学森班荣誉毕业生, 2023。
- 西安交通大学钱学森班荣誉毕业生, 2023。
- 入选西安交通大学少年班; 4,000+ 名申请者中前 2.5%。
- 微软亚洲研究院 Stars of Tomorrow Award of Excellence, 2023。

技能

研究方向: LLM agents、智能体记忆与技能凝练、多模态基础模型、长程智能体、AI 安全、后门/对抗攻防。

编程与系统: Python、PyTorch、Hugging Face、vLLM、OpenAI API、LangChain、Docker、Linux、Bash、Git、C/C++、HTML/CSS、LaTeX; 使用过最多 16 卡多 GPU 实验。

语言: 中文 (母语), 英语 (流利; TOEFL 104)。