

徐彬琰

binyxu@ie.cuhk.edu.hk • +86 159-5123-4880 • 个人主页 • Semantic Scholar • GitHub • LinkedIn

教育背景

香港中文大学

2023.9 – 2027.10 (预计)

信息工程博士研究生; 导师: 张克环教授

GPA: 3.914

加州大学伯克利分校

2021.8 – 2021.12

电子工程与计算机科学交换项目

GPA: 4.0

西安交通大学

2019.9 – 2023.7

自动化工学学士, 钱学森学院, 钱学森班

GPA: 3.92; 排名: 前 5%

• 通过少年班从初中阶段进入西安交通大学; 该选拔项目从 4,000+ 名申请者中录取约 100 人。

研究主线与定位

- 一条主线: 从风险感知到可靠自治的闭环智能——让智能系统在开放环境中感知状态与风险、沉淀记忆与技能, 经外部验证与风险反馈实现可靠、低成本的长期自治。
- 沿同一套“发现失效—外部验证—自治优化”方法演进: 早期在多模态与系统场景中发现并验证 AI 失效模式, 近期转向长程 LLM 智能体的状态管理、记忆维护与技能蒸馏。
- 主导 4 篇 CCF-A 已录用、4 篇在投的第一/共同第一作者工作, 覆盖长程 LLM agents、多模态基础模型与 AI 风险; 擅长系统搭建、benchmark/ablation 与 artifact 发布。

代表论文与投稿

4 篇 CCF-A 类会议已录用、4 篇在投, 均为第一/共同第一作者工作。

一、长程自主智能体: 状态、记忆与技能

[1] **LLM Agents Are Latent Context Managers: Eliciting Self-Managed Context via Dashboard**  在投

Binyan Xu, Haitao Li, Kehuan Zhang.

状态感知: 让 LLM agent 感知并管理自身工作状态, 提升长程任务能力。

[2] **From Multi-Agent to Single-Agent: When Is Skill Distillation Beneficial?**  在投

Binyan Xu, Dong Fang, Haitao Li, Kehuan Zhang.

技能沉淀: 判断何时可将多智能体协作/评测闭环压缩为低成本单智能体技能。

[3] **Contextual Agentic Memory is a Memo, Not True Memory**  在投

Binyan Xu*, Xilin Dai*, Kehuan Zhang. *Equal contribution.

记忆维护: 区分临时上下文检索与真正可复用经验, 重新定义 agent memory。

二、外部审计与语义验证: 为不可信模型建立反馈闭环

[4] **From Internal Diagnosis to External Auditing: A VLM-Driven Paradigm for Online Defense**  ICML 2026

Binyan Xu, Xilin Dai, Fan Yang, Di Tang, Kehuan Zhang.

Poster

外部审计: 以外部 VLM 审计不可信模型的后门预测, 避免依赖模型内部诊断。

[5] **CLIP-Guided Backdoor Defense through Entropy-Based Poisoned Dataset Separation**  ACM MM 2025

Binyan Xu, Fan Yang, Xilin Dai, Di Tang, Kehuan Zhang.

 Oral Presentation

语义验证: 利用 CLIP 语义信号分离毒化图像并移除隐藏后门行为。

三、风险发现与反馈: 从模型脆弱性到自动化决策

[6] **One Surrogate to Fool Them All: Universal and Transferable Adversarial Attacks with CLIP**  CCS 2025

Binyan Xu, Xilin Dai, Di Tang, Kehuan Zhang.

 Oral Presentation

状态迁移: 利用公开 CLIP 的多模态语义表示构造可迁移攻击。

[7] **Breaking Stealth-Potency Trade-off in Clean-Image Backdoors with Trigger Optimization**  AAAI 2026

Binyan Xu, Xilin Dai, Fan Yang, Di Tang, Kehuan Zhang.

 Oral Presentation

风险发现: 揭示生成式 AI 如何构造隐蔽训练集污染并绕过现有视觉防御。

[8] **When Agent Automation Becomes Profitable: Quantify and Insure Autonomous AI Risk**  在投

Binyan Xu, Xilin Dai, Fan Yang, Kehuan Zhang.

风险反馈: 用失败成本与保险定价判断智能体自动化何时具有经济可行性。

项目经历

闭环自主智能体：状态感知、记忆维护与技能内化

2026.1 – 2026.5

腾讯 IEG, 光子工作室群, X-Data Research Team; 青云计划实习

全职研究实习生

- 将长程智能体问题重构为“状态感知—记忆管理—技能内化—成本控制”的系统问题，而非仅扩大上下文或堆叠多智能体流程。
- 主导 *LLM Agents Are Latent Context Managers* [1], 提出智能体缺失对自身上下文状态的 *proprioception*, 设计 VISTA self-managed context 层, 将工作记忆表示为 typed/addressable blocks, 并暴露 token usage、recency 与 budget 等状态。
- 在 LOCA-Bench 75 个长程工具任务上将 Gemini-3-Flash 成功率从 22.7% 提升至 50.7%, 优于 ReAct、SLIM、Active Context Compression 与 Claude Code; 4 个 backbone 均有提升。
- 主导技能蒸馏研究 [2], 提出 *Metric Freedom* 判断何时可将多智能体协作/评测结构内化为单 agent 技能; 在 4 项任务、11 个数据集上以 1.4–15× 更低成本达到或超过原系统。
- 共同主导 agentic memory 研究 [3], 指出当前“记忆”模块多为上下文扩展而非真正记忆系统; 构建评测、消融、统计分析与可复现 artifact, 支撑智能体从临时上下文走向可复用经验。

可控生成式 AI：美学平面设计自动化

2022.7 – 2023.6

微软亚洲研究院, Data, Knowledge and Intelligence; 明日之星实习项目

全职研究实习生

- 共同开发 AI 辅助美学设计系统, 结合版式规划、视觉语言理解与扩散式风格/装饰生成, 面向真实设计中的可控内容生成。
- 实现可控生成模块, 在提升视觉质量的同时降低版式、元素关系与设计约束违背, 为后续研究可控生成、约束满足与人机反馈闭环提供应用侧经验。
- 获得微软亚洲研究院 Stars of Tomorrow Internship Program 的 *Award of Excellence*。

闭环可信 AI 系统：外部审计、风险发现与语义验证

2023.9 – 2026.1

香港中文大学应用安全研究实验室

博士阶段研究

- 将安全研究定位为闭环可信 AI 系统中的“风险感知与外部验证”问题, 覆盖 VLM 外部审计、多模态大模型引导毒化数据分离、CLIP 迁移攻击、生成式 clean-image 后门与自动化 AI 风险分析 [4–8]。
- 提出以 VLM 作为外部审计者的数据无关在线后门防御方法 [4], 将防御从模型内部诊断转向外部语义审计, 适用于不完全信任被部署模型的场景。
- 设计通用触发器优化方法 [7], 在真实 AI 服务（谷歌搜图、百度搜图、淘宝识图）和多模态模型（GPT-4、Claude Sonnet 等）上保持高成功率, 刻画开放模型能力被滥用时的迁移风险。
- 构建 CLIP 引导的毒化数据集分离和通用定向攻击流程 [5,6]; 产出 ICML、AAAI、CCS 与 ACM MM 等 CCF-A 录用/投稿论文, 形成从风险发现到外部语义验证的连续研究积累。

开源与影响力

- 在 github.com/binyxu 开源第一作者工作代码, 覆盖 long-horizon agent 评测、VISTA self-managed context、agentic memory、技能蒸馏、VLM 外部审计、后门攻防与对抗迁移。
- 发布可复现实现与实验 artifact, 将论文贡献沉淀为可复用 benchmark、agent harness、审计流程和攻击/防御 pipeline, 便于社区验证和二次开发。
- Agent-memory 工作发布后引发较广泛讨论, 包括 DAIR.AI 在 X 上转发 (26K+ 浏览、700+ 点赞/收藏)、Facebook AI 社区、YouTube 解读、小红书转载与新智元报道。

荣誉与技能

- **学术服务:** ICML、ICLR、ACM MM、AAAI 正式审稿人; AAAI、ACM CCS、ACM MM 口头报告, ICML poster 展示; Lead TA 指导 40+ 名本科毕业设计学生。
- **荣誉:** 美国大学生数学建模竞赛 Finalist (Top 2%); 入选西安交通大学少年班 (4,000+ 名申请者中前 2.5%); 钱学森班荣誉毕业生/优秀毕业生; 伯克利交换项目一等资助; 微软亚洲研究院 Stars of Tomorrow Award of Excellence。
- **研究方向:** 闭环自主智能、long-horizon LLM agents、agentic memory、self-managed context、self/skill distillation、agent automation/risk、多模态基础模型、AI safety/security。
- **编程与工具:** Python (主力); 熟悉 PyTorch、Hugging Face、vLLM、OpenAI API 与 agent harness、tool-use evaluation、ablation pipeline 及多 GPU 实验 (最多 16 卡)。
- **语言:** 中文 (母语), 英语 (流利; TOEFL 104)。